

Univerzitet u Tuzli
Fakultet elektrotehnike
Telekomunikacije

TEMA:

Weather Image Recognition

Autor:
Azra Razić

Predmet: Prepoznavanje uzoraka
Profesor: vanr.prof.dr.sc. Damir Demirović

Akadska godina:
2021/2022

Tuzla, maj 2022.

Sadržaj

1. Uvod.....	1
2. Feature selection/ odabir značajke	3
3. Histogram amplitude gradijenta	4
4. Struktura kategorije u prepoznavanju vremena	5
5. Šta je strojno učenje?.....	6
6. Jedan od primjera upotrebe ML-a	8
<i>Vertikalne primjene</i>	12
7. Razvrstavanje vremena za više klasa iz pojedinačnih slika	13
8. Učenje rječnika	15
9. Okvir za višestruku klasifikaciju vremenskih prilika	15
10. Rezultati klasifikacije	24
11. Kratak osvrt na postupak	25
Zaključak.....	26
Literatura:.....	27

1. Uvod

Mnoge industrije imaju potrebu identificirati trenutne i prošle vremenske uvjete. Podaci im pomažu planirati, organizirati i/ili optimizirati svoje poslovanje.

Na primjer, poljoprivrednici bi mogli pogledati trenutno vrijeme kako bi odlučili trebaju li se prskalice uključiti ili isključiti. Operateri skijališta mogu odlučiti omogućiti strojeve za pravljenje snijega na temelju različitih vremenskih uvjeta diljem planine. Građevinski radnici mogu planirati zalihe i opremu za kišu koja će im trebati za udaljeno radno mjesto. Trenutno donošenje takvih odluka može zahtijevati ručno gledanje video sadržaja s udaljenih kamera, oslanjanje na vremensku prognozu ili jednostavno gledanje kroz prozor.

U mnogim outdoor aplikacijama za računalni vid, uključene su “loše” vremenske situacije, kao što su izmaglica, magla, kiša, tuča i snijeg. Bitno je otkriti i prepoznati različite vanjske vremenske prilike, naročito u navedenim situacijama. Promatranje vremenskih situacija u meteorologiji još uvijek je manualno i situacija koja se tiče vremena nije potpuno ista čak ni unutar svake od malih regija. Stoga, automatsko prepoznavanje vanjske vremenske situacije na osnovu slike ili videa , dobija sve veću pozornost posljednjih godina.

Prema trajanju i opsegu utjecaja na video ili sliku, vremenske situacije mogu se podijeliti na statično ili postojano vrijeme. U statičnim vremenskim situacijama kao što su sunčano, oblačno, magla, dim, izmaglica i tako dalje, postoji nekoliko ili više stabilnih čestica u atmosferi za ublažavanje i prelamanje ambijenta svjetlosti, tako da je njihov utjecaj na kvalitetu slike relativno stabilniji, uglavnom za degradaciju zamućenja.

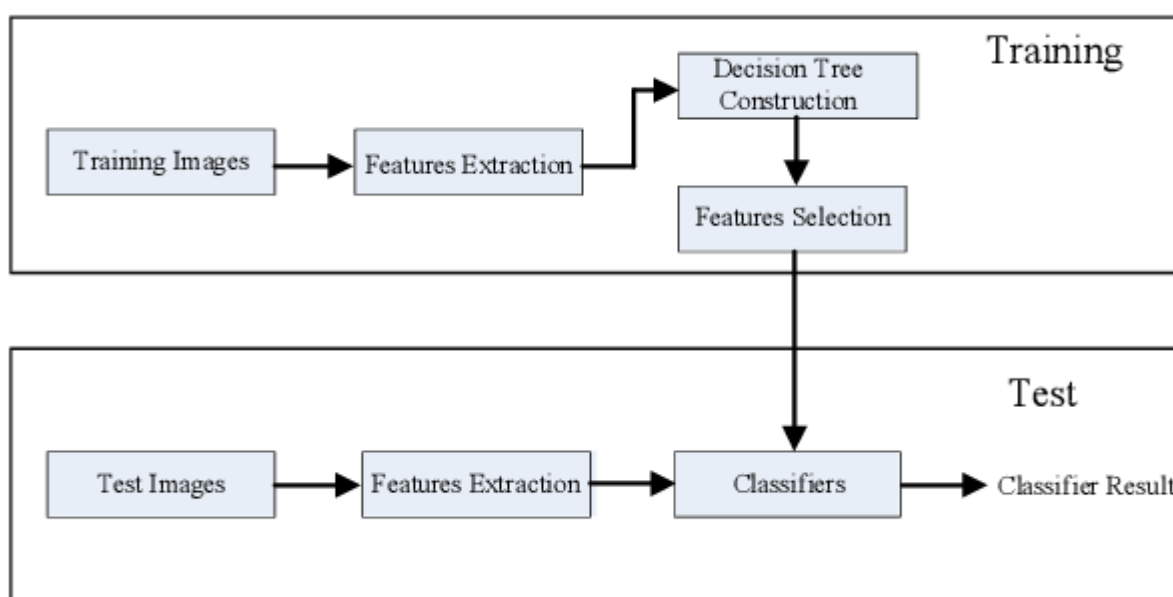
Dinamične vremenske situacije, kao što su kiša, snijeg, oluja, tuča i tako dalje, čine slabljenje i lom svjetla okoline za kretanje nestabilnih čestica u atmosferi, i degradacije kvalitete slike su uglavnom zamućenje pokreta, šum u točkama i šum tragova kretanja. Zbog razlika u procesu slikanja, na primjer, uticaj obima kiše ili snijega, učinak degradacije će biti drugačiji. Dakle, identificiranje i izučavanje različitih dinamičnih pojava u različitim okruženjima i situacijama je jedna od poteškoća u trenutnim istraživanjima.



Slika 1: Vremenske prilike

2. Feature selection/ odabir značajke

Za svaki problem prepoznavanja uzoraka važno je odabrati odgovarajuće značajke. Prepoznavanje vremena sa slika razlikuje se od opće klasifikacije slika. Zadatak klasifikacije slika uvijek provodimo odabirom zanimljivih tačaka kao značajki ili otkrivanjem objekta koji se pojavljuje u sceni. Nepraktično je za naš projekt jer pod različitim vremenskim uvjetima mogu biti idenične značajke i identične zanimljive tačke. Dakle, primjena iste vrste značajki kao opća klasifikacija slika nije ispravna. Predlažemo tipične značajke u niske razine vida analizirajući svojstva slika u različitim vremenskim uvjetima.



Slika 2: Framework

3. Histogram amplitude gradijenta

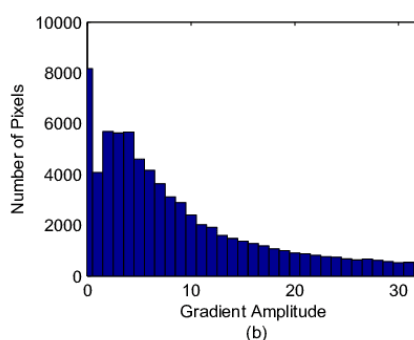
Slike u različitim vremenskim uvjetima poprimaju različite stepene zamućenja. U sunčanim su danima slike uvijek oštrije, dok su zamućene u kišnim danima. Pogotovo kada kapi kiše prekrije kameru, slika je uvijek više zamućena i vrijednosti piksela na slikama su izravnane. Gradijent je savršen alat mjerenja oštine. Općenito, što je veći gradijent, to je više moguće da će biti sunčano. Izračunavamo amplitudu gradijenta prema (1) i formiramo histogram amplitude gradijenta.

$$M(x, y) = \sqrt{G_x(x, y)^2 + G_y(x, y)^2} . \quad (1)$$

Izraz (1) prikazuje „sunčane“ i „kišne slike“ i njihove odgovarajuće histograme amplituda gradijenta. Nalazimo da je distribucija histograma drugačija - ravnija je za kišne slike nego za sunčane slike. Ima više piksela niske vrijednosti na slici kiše i više piksela visoke vrijednosti na sunčanim slikama(slici sunca).



(a)




(b)

(a) A sunny image

(b) Histogram of gradient amplitude of (a)



(c)



(d)


(c) A rainy image

(d) Histogram of gradient amplitude of (c)

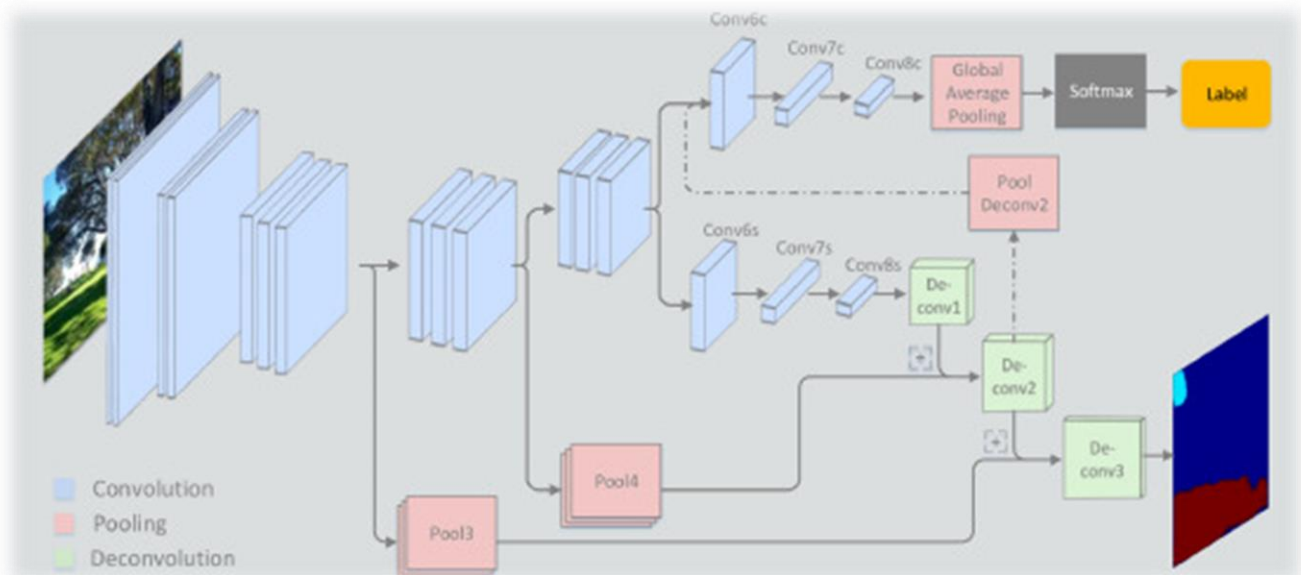
Slika 3: Histogram amplitude gradijenta

4. Struktura kategorije u prepoznavanju vremena

U općim pitanjima klasifikacije slika, ne postoji logičan odnos između klasa a smatra se da su svi razredi neovisni.



Slika 4: 3 različite boje kruga ili elipse predstavljaju 3 različite klase podataka




Slika 5: Weather recognition via classification labels

5. Šta je strojno učenje?

Računari su u prošlosti mogli raditi samo ono za što su bili programirani. Strojno učenje omogućava im da uče na sličan način kako to rade ljudi: stroj prikuplja znanje bazirano na prošlom iskustvu. Umjesto da mu se stalno mora ažurirati softverski kod, on je, kako vrijeme prolazi, samostalno sposoban poboljšavati svoj rad. Strojno učenje može biti poprilično komplicirano, ali pojednostavljeno rečeno, recimo da želimo program koji može razlikovati slike jabuka od slika banana. Prvo mu damo nekoliko označenih primjera jednog i drugog, a on na njima traži uzorke kako bi ih zapamtio. Nakon toga, kad mu damo neoznačene slike, on koristi ova sjećanja da bi odredio što je jabuka, a što banana, bez da mu mi pomažemo.

Neki jednostavno eksperimentiraju sa strojnim učenjem da vide do kuda će to dovesti. Možda ste čuli za pojam neuralna mreža o kojem se u zadnje vrijeme dosta priča; riječ je o posebnom načinu strojnog učenja koje pojedinci koriste kako bi stvarali zanimljive projekte. I dok se mnoge stvari ovdje čine pozitivnima, ljudi sve više brinu da će zbog strojnog učenja gubiti poslove. To ovisi o industriji, ali potencijal za dramatičnu promjenu mnogih poslova, poput vozača, bankara, čak i određenih liječnika, je definitivno tu. Mnogi su zabrinuti zbog moralnosti strojnog učenja i naglašavaju njegov potencijal da naruši vašu privatnost. Primjerice, ne bi bilo teško stvoriti program koji bi prikupljao vaše poruke i onda se u razgovoru s nekim predstavljao kao vi. Strojno učenje može biti vrlo moćan alat, ali važno je imati na umu i njegove negativne posljedice i efekte.



Slika 6:Machine Learning



Slika 7: Machine learning 2

6. Jedan od primjera upotrebe ML-a

Korištenje strojnog učenja (ML) nudi potencijal za automatizaciju pružanjem digitalnog oka. Tačnije, ako bi se ML model za prepoznavanje slika mogao izgraditi za prepoznavanje uvjeta jednostavnim gledanjem slika vremena, mogao bi se primijeniti u brojnim scenarijima. Na primjer, prijenos kamere na farmi mogao bi se obraditi ML modelom postavljenim na IoT uređaju na rubu (npr. na pametnoj kameri).

Taj se model zatim može koristiti za automatsko određivanje trenutnih vremenskih uvjeta i u skladu s tim omogućiti ili onemogućiti ventile za prskalice. Kako bismo demonstrirali ovaj slučaj upotrebe, napravljen je model u PerceptiLabsu obučen za klasificiranje četiri različite vrste vremena. Korištene su 1123 slike iz skupa podataka o vremenu za više klasa za klasifikaciju slika: oblačno, sjaj, izlazak sunca i kiša.



Slika 8: Slike iz data set-a

Prethodno smo obrađivali slike kako bismo promijenili veličinu svake od njih u razlučivost od 224x224 piksela i stvorili .csv datoteku za mapiranje slika u njihove odgovarajuće klasifikacijske enumeracije. U nastavku je djelomični primjer kako izgleda .csv datoteka:

image_path	target
cloud/cloud_0.jpeg	0
rain/rain_208.jpeg	1
shine/shine_208.jpeg	2
sunrise/sunrise_212.jpeg	3

Slika 9: Primjer .csv file

Naš model je napravljen sa samo tri komponente:

Component 1: ResNet50	include_top=No, input_shape=(224,224)
Component 2: Dense	Activation= ReLU , Neurons=128
Component 3: Dense	Activation= Softmax , Neurons=10

Slika 10: Tri komponente



Slika 11: Rezultati



Slika 12: Rezultati pt2

Treniran je model s 10 epoha u serijama od 50, koristeći ADAM optimizator, stopu učenja od 0,001 i funkciju gubitka unakrsne entropije.

Uz vrijeme treninga od oko četiri minute, uspjela se postići tačnost treninga od 99,4% i tačnost provjere od 95,9%.

Na sljedećoj snimci zaslona iz PerceptiLabsa možete vidjeti kako je tačnost porasla na ove postotke tijekom 10 epoha, pri čemu se veći dio povećanja dogodio unutar samo prve tri epohe:



Slika 13: Porast tačnosti

Istovremeno, gubitak se najviše smanjio tijekom prvih pet do šest epoha:



Slika 14: Gubitak

Vertikalne primjene

Mogućnost automatskog identificiranja trenutnih vremenskih uvjeta pomoću prepoznavanja slika može igrati ključnu ulogu u industrijskim IoT (IIoT) aplikacijama u rasponu od poljoprivrede do nafte i plina i dalje. Tvrtke ga mogu koristiti za kontrolu resursa, uštedu energije i optimizaciju svog poslovanja.

Sam model bi se također mogao koristiti kao osnova za prijenos učenja za stvaranje naprednijih modela koji detektiraju druge vremenske uvjete ili čak analiziraju dano okruženje.

Ovaj slučaj upotrebe je jednostavan primjer kako se ML može koristiti za prepoznavanje vremenskih uvjeta pomoću prepoznavanja slika.



Slika 15: Internet of things

7. Razvrstavanje vremena za više klasa iz pojedinačnih slika


Za razliku od gore navedenih radova, predlažemo novi okvir za razvrstavanje vremena za više klasa iz pojedinačnih slika u bilo kojoj sceni, koja se temelji na učenju rječnika i višestrukoj jezgri učenja (MKL). Implementacija ideje kernela, međutim, sa sobom nosi značajne izazove. Prvo, teško je pronaći prikladne značajke za razlikovanje različitih vremenskih uvjeta. Drugo, značajke mogu biti heterogene, a vektori značajki su visokodimenzionalni. S ciljem rješavanja navedenih izazova, mi najprije izdvajamo više značajki za predstavljanje različitih vremenskih uvjeta. Na primjer, značajke neba i sjene mogu ukazivati sunčano vrijeme.

Značajka tamnog kanala može ukazivati na izmaglicu. Značajka podudaranja predloške pločice temeljena na HOG (Histogram orijentiranih gradijenta) može ukazivati na kišno vrijeme. Snježna pahulja značajka buke može ukazivati na snježnu značajku. Neke globalne značajke poput kontrasta i zasićenosti se koriste za razlikovanje više klasa vremena. Poboljšati diskriminaciju prikaza slike i poboljšati izvedbu višestruke klasifikacije vremenskih uvjeta, naš pristup izdvaja više vremenskih značajki i uči više rječnika na temelju tih značajki. Zatim, koristimo višestruko algoritam učenja kernela za učenje optimalne linearne kombinacije jezgri značajki za odabir dobrog podskupa značajki.



Doprinosi ovih značajki su:

- Predlažemo višerazrednu klasifikaciju vremena bez scene spajanjem više značajki slike i učenjem više rječnika. Prema našim saznanjima, ovo djelo je jedno od prvih pokušaja jednoslojne višeklasne vremenske klasifikacije.
- Predlažemo dvije metode za otkrivanje kišne pruge i snježne pahulje na pojedinačnim slikama. Prvo, predlažemo metodu podudaranja predložka temeljenu na His togramu orijentacijskih gradijenta (HOG) za otkrivanje kišnih pruga. Štoviše, smatramo pahuljicu kao vrstu buke i definiramo nekoliko pravila za otkrivanje i opišemo pahulje.
- Prikupljamo set slika na otvorenom koji sadrži 20 K slika tzv.MWI (Multi-class Weather Image) set koji pruža opsežnu ispitnu bazu za evaluaciju postojećih metoda i razvoj novih pristupa.



Slika 16: Trg Tiananmen u različitim vremenskim uslovima

8. Učenje rječnika

Učenje rječnika je učinkovita tehnika učenja značajki.

Za zadatke klasifikacije slika, naučeni rječnik može poslužiti za predstavljanje slika, što olakšava klasifikaciju. Autori su predložili supervised metodu učenja za učenje rječnika u prostoru izvorne slike

i odgovarajuću matricu transformacije.

Autori su predložili rijetku tehniku kodiranja u visokom dimenzionalnom prostoru obilježja korištenjem nekog implicitnog pinga mape značajki. Primijenili su ga na klasifikaciju slika, prepoznavanje lica i aproksimaciju kernel matrice. Međutim, ti se radovi usredotočuju na klasifikaciju objekata na osnovnoj razini koja bi mogla propasti u zadatku klasifikacije vremena zbog razlike između različitih vremenskih prilika, uvjeti su suptilni i sitni.

9. Okvir za višestruku klasifikaciju vremenskih prilika

U ovom ćemo odjeljku predložiti opći okvir za višestruku klasifikaciju vremenskih prilika na temelju pojedinačnih slika. Okvir je sastavljen izdvajanjem više značajki uključujući nebo, sjenu, kišnu prugu, pahulje, tamni kanal, kontrast i zasićenje; učenje više rječnika; značajke selekcije i klasifikacije putem naučenog rijetkog koda i višestruke jezgre algoritma učenja. Zatim ćemo opisati svaku komponentu u detalj.





Fig. 2. (a) Top: input images of different weather. Bottom: the detected sky regions. (b) Shadow detection result for a sunny image. (c) Shadow detection result for a haze image. (For interpretation of the references to color in this figure caption, the reader is referred to the web version of this paper.)

▪ Ekstrakcija više značajki

Za svaki problem prepoznavanja uzoraka važno je odabrati ispravne značajke. Vremenska klasifikacija iz slike se razlikuje od opće klasifikacije slika, te je nepraktično koristiti tradicionalne značajke za naš problem jer može postojati isti objekt i zanimljive točke u različitim vremenskim uvjetima. Stoga nije prikladno za primjenu iste vrste značajki kao i opća klasifikacija slika. Predlažemo nekoliko značajki niske razine analizom svojstava slika pod različitim vremenskim uvjetima. Točnije, smatramo obilježja neba, sjene, kišne pruge, snježne pahulje i mraka kanal kao lokalna obilježja tako da svaki od njih može označiti jedno određeno vrijeme, te uzeti u obzir značajku kontrasta i zasićenja kao globalne značajke koje mogu ukazivati na više vremenskih prilika.

▪ Nebo

Nebo bi moglo biti najočitija značajka koja označava sunčano vrijeme na slikama. Sunčane slike imaju čistu nebo ili jake sjene, dok ostale vremenske slike imaju sivu boju neba ili slabe sjene. Za dio neba, prvo detektiramo nebo regiju na slici predloženim metodom. Zatim, izdvojimo a i b kanale u Lab prostoru boja neba regije za formiranje 200-dimenzionalnog vektora obilježja.



Slika 17: Prepoznavanje vremena na osnovu neba

- **Sjena**


Međutim, nemaju sve sunčane slike područje neba. Za sliku bez regije neba, jake sjene tla mogu ukazivati na sunčano vrijeme. Primjenjujemo alat za detekciju sjena i slijedimo implementacija kako bi se formirao 10-dimenzionalni vektor značajki za svaku sliku.



Slika 18: Prepoznavanje vremena na osnovu sjene

▪ Traka kiše

Otkrivanje kiše i snijega na pojedinačnim slikama bilo je rijetko proučavano u literaturi, gdje nema vremenskih informacija čineći problem vrlo izazovnim. Neki radovi koristili su značajku HOG za kišne pruge uklanjanje ili otkrivanje. Trakice kiše trebale bi padati u istoj orijentaciji.



Slika 19: Prepoznavanje vremena na osnovu trake kiše

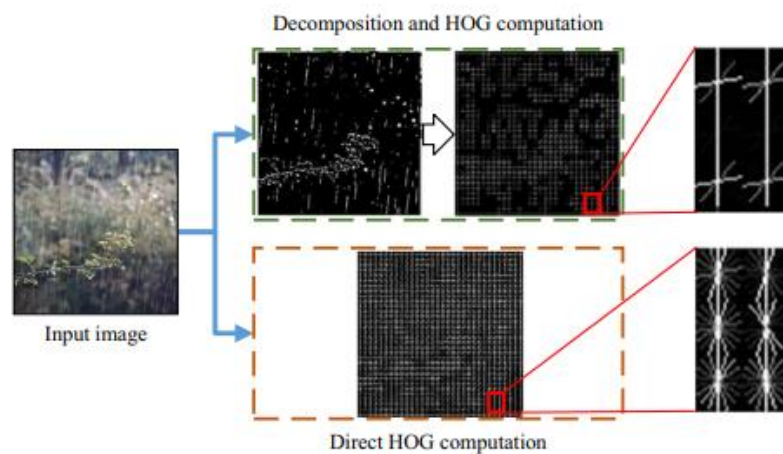


Fig. 3. The HOG figures of the high-frequency part and the original input image.

- **Pahuljica**


Kao što je spomenuto u gornjem odjeljku, teško je otkriti snijeg, posebno u pojedinačnim slikama. Snijeg je lagan i mekan, a kad ga ima, tu je i vjetar, pahulje će promijeniti svoj izvorni smjer i letjeti bilo gdje. Teško je opisati pravilo leteće pahulje, jer je putanja snijega neuređena. Snježne pahulje smatramo nekom vrstom buke.



Slika 20: Pahuljice

▪ Tamni kanal

Slike bez magle sadrže neke piksele koji imaju vrlo niske intenzitete u barem jednom kanalu boja, tj. minimalni intenzitet u takvom flasteru trebao bi imati vrlo nisku vrijednost. Dakle, mi upotrijebimo tamni kanal da označimo vrijeme magle. Koristimo srednju vrijednost od intenziteta tamnih kanala u tim mrljama kako bi se formirao vektor 100-dimenzionalnih značajki.



Comparative haze removal results. From left to right: input image, the results of He's method [9], [15], Jiang's method [11], Method A, Method B, and Method C.

Slika 21: Tamni kanal



Fig. 4. Sample images in the MWI dataset.

Table 1
The distribution statistics on MWI dataset.

Label	Sunny	Rainy	Snowy	Haze
Number	10815	2342	2226	5004

Table 2
Features used in the experiments.

Type	Features	Description
Local features	Sky	Channels a and b of Lab color space of the sky region
	Shadow	The distance between a boundary and its k -nearest neighbors in sunny boundary set
	Rain streak	The HOG similarity between rain streak patches templates
	Snowflake	The histogram of intensity and hue of the snowflake patches
Global Features	Dark channel	The minimum intensity values in patches
	contrast	The difference in color and brightness
	saturation	One of three coordinates in the HSV color space

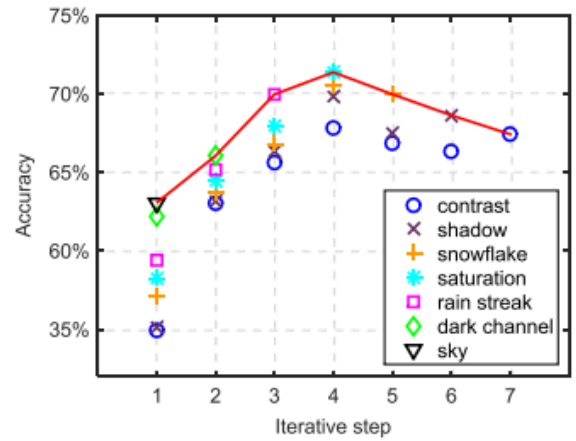


Fig. 5. Performance of feature combination with new features progressively added to MKL.

Sunny	0.70	0.01	0.24	0.05
Rainy	0.01	0.57	0.32	0.10
Snowy	0.07	0.20	0.67	0.07
Haze	0.03	0.01	0.04	0.92
	Sunny	Rainy	Snowy	Haze

Fig. 6. Classification accuracy confusion matrix of the proposed method on MV dataset.

Table 5

Classification results of related methods on MWI dataset.

	[2]	[3]	[6]	[27]	Proposed
Accuracy	0.2267	0.1889	0.4158	0.5944	0.7139

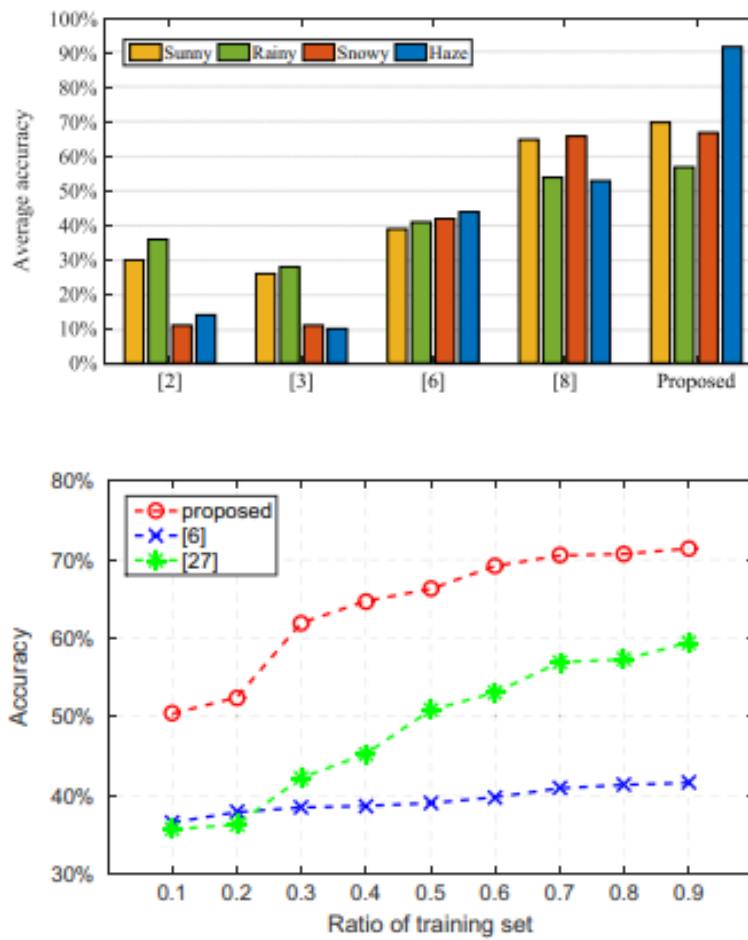


Fig. 8. Classification accuracy on different number of training samples via related methods.

10. Rezultati klasifikacije




Fig. 9. Classification results. (a) Sunny images. (b) Rainy images. (c) Snowy images. (d) Haze images.



Fig. 10. Two rainy images mis-detected as snowy images.

11. Kratak osvrt na postupak

Koristili smo MKL algoritam kako bismo naučili optimalne težine za sve značajke i odabrali optimalnu kombinaciju značajki.

Tablica 3 prikazuje pondere dobivene MKL-om i klasifikaciju tačnosti svake značajke. Koristimo sk, sh, ra, sn, da, co i sa to označava nebo, sjenu, kišnu crtu, snježnu pahulju, tamni kanal, kontrast, i značajke zasićenja, respektivno. Vidimo da obilježje s većom težinom ima bolju klasifikaciju

tačnost. Značajka Sky ima najveću težinu i najbolju preciznost. To znači da značajka neba daje najveći doprinos uspješnosti klasifikacije. Stoga odabiremo obilježje neba kao početak testiranja izvedbe i pronalaženja optimalne značajke kombinacija. Kombiniramo druge značajke sa značajkom neba za testiranje, odnosno, tada će se kombinacija s najboljom izvedbom odabrati kao novi početak. Ovaj postupak ponavljamo dok učinak prestaje rasti. Kao što je prikazano na slici, kombinacija neba, tamnog kanala, kišne pruge i zasićenja čini druge kombinacije. U sljedećim eksperimentima, mi odaberite ovu kombinaciju kao optimalni izbor značajki za naš zadatak. Ovaj postupak može smanjiti složenost izbjegavanjem nepotrebnih ekstrakcija značajki i rijetkog kodiranja.

Zaključak

Predstavili smo okvir za višeklasnu klasifikaciju vremena iz pojedinačnih slika u bilo kojoj sceni. Naš pristup zahtijevao je učenje rječnika za svaku značajku kako bismo poboljšali diskriminaciju predstavljanja slike i poboljšali izvedbu višestrukih klasifikacija vremena. Koristili smo MKL algoritam za učenje optimalne linearne kombinacije jezgri značajki. Testirajući naš pristup, prikupili smo MWI (Multi-class Weather Image) skup. Procijenili smo naš pristup skupu podataka i rezultati pokazuju učinkovitost naše metode.

Ovo se može primijeniti za otkrivanje i posmatranje vremenskih uvjeta, analiza slike/video, poboljšanje pouzdanosti sistema video nadzora, te u mnogobrojne druge svrhe.

Računalni vid je grana računalne znanosti za prepoznavanje ili klasifikaciju slika koje mogu pomoći u klasificiranju vremenskih slika koje ne ovise o vremenskim prognozama s interneta. Ova studija ima za cilj klasificirati vremenske slike pomoću konvolucijske neuronske mreže (CNN) s transfer učenjem.

Literatura:

1. <https://www.kaggle.com/code/hamzamanssor/weather-recognition-using-deep-learning-models>
2. Y. Shi, Y. Li, J. Liu, X. Liu, and Y. L. Murphey, "Weather recognition based on edge deterioration and convolutional neural networks," in *Proceedings of the 2018 24th International Conference on Pattern Recognition (ICPR)*, pp. 2438–2443, IEEE, Beijing, China, August 2018. View at: [Publisher Site](#) | [Google Scholar](#)
3. K. Chen, F. Chen, K. Li et al., "An early warning method for highway traffic accidents based on bayesian networks," in *Proceedings of the 2019 International Conference on Artificial Intelligence and Computer Science - AICS 2019*, pp. 111–116, ACM, Wuhan, China, July 2019. View at: [Google Scholar](#)
4. P.-J. Hsieh, G.-Y. Chen, I.-C. Chiang, and J.-W. Perng, "Path planning design for vehicle driving assist systems," in *Proceedings of 2018 International Conference on System Science and Engineering (ICSSE)*, pp. 1–6, IEEE, Taipei, Taiwan, June 2018. View at: [Publisher Site](#) | [Google Scholar](#)
5. Y. Liu, "Big data technology and its analysis of application in urban intelligent transportation system," in *Proceedings of the 2018 International Conference on Intelligent Transportation, Big Data & Smart City (ICITBS)*, IEEE, Xiamen, China, January 2018. View at: [Publisher Site](#) | [Google Scholar](#)
6. C. Dannheim, C. Icking, M. Mäder, and P. Sallis, "Weather detection in vehicles by means of camera and LIDAR systems," in *Proceedings of the 2014 Sixth International Conference on Computational Intelligence, Communication Systems and Networks*, pp. 186–191, IEEE, Tetova, Macedonia, May 2014. View at: [Publisher Site](#) | [Google Scholar](#)
7. J. Guerrero-Ibáñez, S. Zeadally, and J. Contreras-Castillo, "Sensor technologies for intelligent transportation systems," *Sensors*, vol. 18, no. 4, p. 1212, 2018. View at: [Publisher Site](#) | [Google Scholar](#)
8. A. Voulodimos, N. Doulamis, A. Doulamis, and E. Protopapadakis, "Deep learning for computer vision: a brief review," *Computational Intelligence and Neuroscience*, vol. 2018, Article ID 7068349, 13 pages, 2018. View at: [Publisher Site](#) | [Google Scholar](#)

9. A. Jindal, A. Dua, K. Kaur, M. Singh, N. Kumar, and S. Mishra, "Decision tree and SVM-based data analytics for theft detection in smart grid," *IEEE Transactions on Industrial Informatics*, vol. 12, no. 3, pp. 1005–1016, 2016. View at: [Publisher Site](#) | [Google Scholar](#)
10. Q. Li, Y. Kong, and S.-M. Xia, "A method of weather recognition based on outdoor images," in *Proceedings of 2014 International Conference on Computer Vision Theory and Applications (VISAPP)*, pp. 510–516, IEEE, Lisbon, Portugal, January 2014. View at: [Google Scholar](#)
11. S. G. Narasimhan, C. Wang, and S. K. Nayar, "All the images of an outdoor scene," in *Computer Vision-ECCV 2002*, pp. 148–162, Springer, Berlin, Germany, 2002. View at: [Publisher Site](#) | [Google Scholar](#)
12. A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," *Communications of the ACM*, vol. 60, no. 6, pp. 84–90, 2017. View at: [Publisher Site](#) | [Google Scholar](#)
13. K. Simonyan and A. Zisserman, "Very deep convolutional networks for large-scale image recognition," <https://arxiv.org/abs/1409.1556>. View at: [Google Scholar](#)
14. P. Tang, H. Wang, and S. Kwong, "G-MS2F: GoogLeNet based multi-stage feature fusion of deep CNN for scene recognition," *Neurocomputing*, vol. 225, pp. 188–197, 2017. View at: [Publisher Site](#) | [Google Scholar](#)
15. K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, IEEE, Las Vegas, NV, USA, June 2016. View at: [Publisher Site](#) | [Google Scholar](#)
16. S. Ren, K. He, R. Girshick, and J. Sun, "Faster r-cnn: towards real-time object detection with region proposal networks," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 39, no. 6, pp. 1137–1149, 2017. View at: [Publisher Site](#) | [Google Scholar](#)
17. L.-C. Chen, Y. Zhu, G. Papandreou, F. Schroff, and H. Adam, "Encoder-decoder with atrous separable convolution for semantic image segmentation," in *Computer Vision-ECCV 2018*, pp. 833–851, Springer, Berlin, Germany, 2018. View at: [Publisher Site](#) | [Google Scholar](#)
18. M. Elhoseiny, S. Huang, and A. Elgammal, "Weather classification with deep convolutional neural networks," in *Proceedings of the 2015 IEEE International Conference on Image Processing (ICIP)*, pp. 3349–3353, IEEE, Quebec City, QC, Canada, September 2015. View at: [Publisher Site](#) | [Google Scholar](#)

19. C. Lu, D. Lin, J. Jia, and C.-K. Tang, "Two-class weather classification," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 39, no. 12, pp. 2510–2524, 2017. View at: [Publisher Site](#) | [Google Scholar](#)
20. Z. Zhu, L. Zhuo, P. Qu, K. Zhou, and J. Zhang, "Extreme weather recognition using convolutional neural networks," in *Proceedings of the 2016 IEEE International Symposium on Multimedia (ISM)*, pp. 621–625, IEEE, San Jose, CA, USA, December 2016. View at: [Publisher Site](#) | [Google Scholar](#)
21. Z. Zhu, J. Li, L. Zhuo, and J. Zhang, "Extreme weather recognition using a novel fine-tuning strategy and optimized GoogLeNet," in *Proceedings of the 2017 International Conference on Digital Image Computing: Techniques and Applications (DICTA)*, pp. 1–7, IEEE, Sydney, Australia, November 2017. View at: [Publisher Site](#) | [Google Scholar](#)
22. D. Mishkin, N. Sergievskiy, and J. Matas, "Systematic evaluation of convolution neural network advances on the imagenet," *Computer Vision and Image Understanding*, vol. 161, pp. 11–19, 2017. View at: [Publisher Site](#) | [Google Scholar](#)
23. X. Qian, E. W. Patton, J. Swaney, Q. Xing, and T. Zeng, "Machine learning on cataracts classification using SqueezeNet," in *Proceedings of the 2018 4th International Conference on Universal Village (UV)*, pp. 1–3, IEEE, Boston, MA, USA, October 2018. View at: [Publisher Site](#) | [Google Scholar](#)
24. B. Zhao, X. Li, X. Lu, and Z. Wang, "A CNN-RNN architecture for multi-label weather recognition," *Neurocomputing*, vol. 322, pp. 47–57, 2018. View at: [Publisher Site](#) | [Google Scholar](#)
25. D. Lin, C. Lu, H. Huang, and J. Jia, "RSCM: region selection and concurrency model for multi-class weather recognition," *IEEE Transactions on Image Processing*, vol. 26, no. 9, pp. 4154–4167, 2017. View at: [Publisher Site](#) | [Google Scholar](#)
26. <https://www.nature.com/articles/s41598-020-57897-9>
27. <https://towardsdatascience.com/use-case-automated-weather-analysis-using-image-recognition-c6b4659557ac>
28. <https://www.precisionag.com/market-watch/customized-weather-forecasts-image-recognition-highlight-ibms-foray-into-agriculture/>